

Aplicación de machine learning para la predicción de churn de comunicación en plataformas CRM multicanal: email, push e in-app

Abraham Trenyan

Resumen: Las plataformas CRM multicanal detectan el desenganche del usuario de forma reactiva, cuando la pérdida de interacción ya ocurrió. Este trabajo propone un modelo de clasificación supervisada que combina señales de comportamiento de email, push e in-app para predecir el *churn* de comunicación antes de que se materialice. El *churn* de comunicación se define como el cese total de interacción con los canales de mensajería mientras el usuario permanece activo en la plataforma, una distinción no explorada en la literatura existente. Utilizando datos públicos de Kaggle, Python y los algoritmos Random Forest y XGBoost, se construye un pipeline de predicción evaluado con AUC-ROC y *recall*, y diseñado para integrarse directamente en una plataforma CRM y activar campañas de re-engagement de forma automática. La propuesta traza un camino viable para transformar la detección del desenganche comunicacional en un proceso predictivo y accionable dentro de las plataformas CRM modernas.

I. INTRODUCCIÓN

Los usuarios de plataformas digitales están hoy expuestos a un volumen muy elevado de comunicaciones de marca a través de canales como el correo electrónico, las notificaciones *push* y los mensajes dentro de la aplicación. Estudios empíricos realizados en contextos móviles reportan medianas de entre 56 y 63 notificaciones diarias por usuario [1], lo que se traduce en una carga de estímulos que puede asociarse con emociones negativas y con el descarte o la desinstalación de las aplicaciones responsables [1, 2]. En el dominio específico del *email* marketing, el análisis de Chaparro-Peláez y colaboradores sobre más de cinco mil campañas enviadas a cientos de millones de usuarios identifica una relación significativamente negativa entre la frecuencia de envío y la tasa de apertura [3], y Zhang, Kumar y Cosguner muestran que enviar

por encima o por debajo de la frecuencia óptima puede reducir entre un dieciséis y un treinta y dos por ciento la rentabilidad esperada por cliente a lo largo de su ciclo de vida [4]. En conjunto, esta evidencia sugiere que el *engagement* con los canales de comunicación directa es sensible a la intensidad comunicacional, y que el desenganche puede manifestarse de forma progresiva antes de un abandono total.

El desenganche comunicacional tiene además un impacto económico directo. Trabajos clásicos sobre retención estiman que una reducción del cinco por ciento en la tasa de deserción puede generar aumentos de beneficio de entre un veinticinco y un ochenta y cinco por ciento según la industria [5], y que una mejora del uno por ciento en la retención incrementa el valor de la firma en aproximadamente un cinco por ciento [6]. En el caso de las comunicaciones móviles, los usuarios que reciben notificaciones *push* en sus primeros noventa días presentan tasas de retención aproximadamente tres veces superiores a las de quienes no reciben ninguna [7].

Las plataformas CRM gestionan su base de usuarios a través de estrategias de segmentación: los usuarios se agrupan por características comunes y reciben campañas diseñadas para ese perfil [8, 9]. Este enfoque ha sido el estándar durante años, pero los segmentos se definen con reglas fijas que no se adaptan en tiempo real al comportamiento individual de cada usuario: para cuando un usuario es clasificado como inactivo o en riesgo, en muchos casos ya lleva semanas sin interactuar con ningún canal. La investigación en entornos CRM multicanal confirma que este modelo reactivo deja un margen de mejora considerable, especialmente cuando los datos de comportamiento existen pero no se explotan de forma integrada [8, 9, 10].

El campo del aprendizaje automático ofrece herramientas que pueden cambiar esta dinámica. Los modelos de clasificación supervisada, apoyados en fundamentos teóricos sólidos [11], aprenden patrones a partir de datos históricos y pueden anticipar eventos

antes de que ocurran. Algoritmos como Random Forest [12] y XGBoost [13] han demostrado un rendimiento destacado en tareas de clasificación sobre datos tabulares complejos, incluyendo la predicción de *churn* en banca [14], telecomunicaciones [15, 10] y servicios digitales [16]. Su amplia adopción en investigación aplicada, su disponibilidad como herramientas de código abierto y su capacidad para manejar datos tabulares heterogéneos en escenarios con desbalance de clases los convierten en candidatos especialmente apropiados para el problema planteado [13, 11, 14, 16]. La evaluación de estos modelos suele apoyarse en métricas como AUC-ROC [17], que permiten comparar clasificadores independientemente del umbral de decisión seleccionado. Más allá del *churn* de producto, es decir la cancelación de una cuenta, el aprendizaje automático aplicado al análisis del comportamiento del usuario es una línea metodológica madura, con aplicaciones consolidadas en áreas como la predicción de respuesta a publicidad y el análisis de interacciones digitales [18, 19]. Revisiones sistemáticas específicas del campo de la predicción de *churn* confirman avances importantes en algoritmos de *ensemble* y arquitecturas de *deep learning*, pero también identifican desafíos persistentes relacionados con el desbalance de clases, la interpretabilidad de los modelos y la comparabilidad entre estudios [20, 15]. Estas revisiones se concentran mayoritariamente en el *churn* de producto en dominios como las telecomunicaciones, la banca o los servicios por suscripción, dejando en un segundo plano el comportamiento comunicacional del usuario a través de múltiples canales de mensajería.

Esta brecha se vuelve especialmente visible cuando se considera lo que puede llamarse *churn* de comunicación: el momento en que un usuario deja de interactuar con todos los canales de mensajería de una marca mientras permanece activo en la plataforma. A diferencia del *churn* de producto, el *churn* de comunicación es un fenómeno más sutil y más temprano. Un usuario que deja de abrir correos, ignora las notificaciones *push* y no responde a los mensajes in-app no ha abandonado la plataforma, pero se ha vuelto efectivamente inalcanzable. Desde la perspectiva de la teoría del *engagement* del cliente, que describe el involucramiento del consumidor a partir de dimensiones cognitivas, emocionales y conductuales [21, 22], esto representa un punto de inflexión crítico en el que la intervención preventiva todavía es posible.

Este trabajo propone abordar ese vacío construyendo un modelo de clasificación supervisada que com-

bine señales de comportamiento de los tres canales, email, *push* e in-app, para predecir el riesgo de *churn* de comunicación antes de que este ocurra. El modelo se construye con Python utilizando las bibliotecas scikit-learn y XGBoost, entrenado sobre datos públicos disponibles en Kaggle. El rendimiento del modelo se evalúa con AUC-ROC y *recall*, métricas adecuadas para escenarios donde la prevalencia de la clase positiva debe determinarse empíricamente y donde el costo de no detectar un caso positivo supera al de una activación incorrecta. El objetivo final es que el puntaje de riesgo resultante pueda integrarse directamente en una plataforma CRM y activar campañas de re-engagement de forma automatizada, transformando la detección de desenganche de un proceso reactivo a uno predictivo.

El cuerpo de este trabajo se organiza de la siguiente manera. La sección II revisa el estado del arte en predicción de *churn*, segmentación CRM, análisis de comportamiento de usuario y fatiga comunicacional. La sección III presenta el marco teórico, abarcando los fundamentos del aprendizaje supervisado, los modelos de clasificación seleccionados y las métricas de evaluación. La sección IV describe la metodología, incluyendo la preparación de datos, la ingeniería de *features* y el entrenamiento del modelo. La sección V presenta los resultados y el análisis. La sección VI ofrece las conclusiones y posibles líneas de trabajo futuro.

II. ESTADO DEL ARTE

A. Predicción de *churn* con aprendizaje automático

La predicción de *churn* de cliente es uno de los problemas mejor estudiados dentro del aprendizaje automático aplicado a marketing y servicios. La literatura reciente se concentra en dominios donde la cancelación de cuenta es un evento explícito y medible, principalmente telecomunicaciones [10, 15], banca minorista [14] y servicios digitales por suscripción [16]. Los algoritmos de ensamble basados en árboles se han consolidado como referencia metodológica, en buena medida por su rendimiento sobre datos tabulares y por la disponibilidad de implementaciones eficientes en bibliotecas de código abierto [14, 16].

Las revisiones sistemáticas del campo confirman que la predicción de *churn* ha incorporado de forma progresiva técnicas más sofisticadas, desde modelos clásicos hacia ensambles y arquitecturas de *deep learning*, y al mismo tiempo identifican desafíos persistentes vinculados al desbalance de clases, la interpre-

tabilidad de los modelos y la falta de comparabilidad entre estudios debido a la heterogeneidad de datasets y métricas [15, 20]. Estas revisiones, sin embargo, mantienen el foco en el churn entendido como cancelación de cuenta, sin abordar formas más tempranas o parciales de desenganche del usuario.

B. Segmentación y CRM multicanal

La gestión de la relación con el cliente en plataformas multicanal se apoya tradicionalmente en estrategias de segmentación que agrupan a los usuarios según características demográficas, transaccionales o comportamentales, y que asignan campañas diseñadas para cada segmento [8]. La literatura sobre métodos de segmentación en e-commerce muestra una evolución desde reglas heurísticas hacia técnicas de clustering basadas en datos, pero conserva en gran medida una lógica estática, en la que los segmentos se definen periódicamente y no se actualizan al ritmo del comportamiento individual [8].

La revisión de Verhoef y colaboradores sobre CRM en entornos multicanal de venta minorista plantea, ya hace más de una década, que el potencial de las plataformas data-rich queda subutilizado cuando los datos de interacción existen pero no se integran de forma efectiva en los modelos de decisión operativos [9]. Esa observación sigue vigente: la mayoría de las implementaciones CRM actuales mantienen un enfoque reactivo, en el que la intervención llega después de que el desenganche ya se manifestó, y rara vez incorporan modelos predictivos que combinen señales de múltiples canales de mensajería en tiempo real.

C. Análisis de comportamiento de usuario

El análisis de comportamiento de usuario apoyado en aprendizaje automático es una línea metodológica madura, con aplicaciones consolidadas en personalización, sistemas de recomendación, detección de fraude y modelado de respuesta [18]. La revisión de Martín y colaboradores ofrece un mapa amplio del campo, identificando los modelos más utilizados, las fuentes de datos típicas y los tipos de tareas abordadas, y deja en evidencia que el comportamiento digital del usuario se ha estudiado intensamente desde múltiples ángulos [18].

Un subcampo particularmente desarrollado es la predicción de respuesta en publicidad online, donde el problema central consiste en estimar la probabilidad de que un usuario interactúe con un anuncio, ya sea mediante un click o una conversión posterior [19].

Las técnicas empleadas en este dominio comparten una base metodológica común con la predicción de churn, dado que ambos problemas se formulan como tareas de clasificación binaria sobre datos comportamentales con clases desbalanceadas. Sin embargo, el énfasis se ha puesto históricamente sobre la predicción de eventos positivos de respuesta, dejando menos explorado el modelado predictivo de la ausencia sostenida de interacción.

D. Frecuencia comunicacional y fatiga de usuario

La relación entre la intensidad de las comunicaciones de marca y la respuesta del usuario ha sido estudiada con profundidad tanto en el canal de notificaciones móviles como en el de email marketing. En el caso de las notificaciones push, el estudio in-situ de Pielot y colaboradores cuantifica el volumen al que están expuestos los usuarios y asocia ese volumen con emociones negativas y con la decisión de descartar o desinstalar aplicaciones [1], mientras que Okoshi y colaboradores abordan la carga cognitiva generada por notificaciones interruptivas y exploran mecanismos para mitigar su impacto [2]. Por el lado positivo, el informe técnico de Airship documenta diferencias significativas en las tasas de retención entre usuarios que reciben push notifications durante los primeros días de uso y aquellos que no las reciben [7].

En el dominio del email marketing, el análisis a gran escala de Chaparro-Peláez y colaboradores identifica una relación negativa entre la frecuencia de envío y la tasa de apertura de los correos [3], y el modelo dinámico de Zhang, Kumar y Cosguner muestra que apartarse de la frecuencia óptima, ya sea por exceso o por defecto, deteriora la rentabilidad esperada por cliente a lo largo de su ciclo de vida [4]. Esta evidencia se enmarca dentro de un campo de investigación consolidado, pero generalmente abordado canal por canal de forma aislada, sin integrar las señales de email, push e in-app en un único modelo de comportamiento del usuario.

III. MARCO TEÓRICO

A. Aprendizaje automático supervisado

El aprendizaje automático supervisado consiste en inducir una función de predicción a partir de un conjunto de ejemplos en los que cada observación está acompañada de una etiqueta conocida [11]. A diferencia del aprendizaje no supervisado, que busca estructuras latentes en datos sin etiquetar, el supervisa-

do dispone de una variable objetivo que guía el entrenamiento y permite cuantificar el error de predicción de forma directa. Cuando esa variable objetivo es categórica y toma dos valores posibles, el problema se denomina clasificación binaria.

El churn de comunicación, definido como el cese de interacción con los canales de mensajería mientras el usuario permanece activo en la plataforma, encaja naturalmente en este paradigma. Para cada usuario es posible construir un vector de features comportamentales y asignarle una etiqueta binaria que indica si entró o no en estado de churn de comunicación dentro de una ventana temporal definida. El modelo aprende entonces a mapear ese vector de comportamiento a una probabilidad de churn, generando un puntaje accionable para la plataforma CRM.

B. Evaluación y generalización

La capacidad de un modelo de generalizar a datos no vistos es la propiedad fundamental que determina su utilidad práctica [11]. Un modelo que memoriza los datos de entrenamiento sin capturar patrones genuinos, fenómeno conocido como sobreajuste, presenta un rendimiento engañosamente alto durante el entrenamiento y un rendimiento deficiente cuando se aplica a nuevos datos. Para mitigar este riesgo el conjunto de datos se particiona en al menos dos subconjuntos: uno de entrenamiento, sobre el cual se ajusta el modelo, y uno de prueba, reservado para estimar el rendimiento sobre datos nuevos.

Cuando los datos son limitados o cuando se requiere comparar configuraciones de hiperparámetros, se recurre a la validación cruzada, que repite el procedimiento de partición varias veces sobre subconjuntos distintos y promedia las métricas obtenidas. En problemas de clasificación con clases desbalanceadas, como el churn de comunicación, la variante apropiada es la validación cruzada estratificada, que preserva la proporción de cada clase en todos los pliegues y evita que algún fold quede sin casos positivos.

C. Modelos basados en árboles

Los árboles de decisión particionan recursivamente el espacio de features mediante reglas condicionales simples, construyendo una estructura jerárquica de nodos en la que cada hoja representa una predicción [11]. En tareas de clasificación, cada partición se elige optimizando una medida de impureza, típicamente el índice de Gini o la entropía, con el objetivo de separar las clases lo más limpiamente posible. La principal

ventaja de un árbol es la interpretabilidad, ya que sus decisiones pueden seguirse rama por rama. La principal limitación es la tendencia al sobreajuste, especialmente cuando se permite que crezca hasta hojas puras.

El método de Random Forest, propuesto por Breiman [12], mitiga esa limitación entrenando un ensamble de árboles sobre muestras bootstrap del conjunto de entrenamiento y promediando sus predicciones. Cada árbol considera solo un subconjunto aleatorio de features en cada partición, lo que decorrelaciona las predicciones del ensamble y reduce significativamente la varianza. Random Forest maneja con eficacia datos tabulares heterogéneos, no requiere escalado previo de las features numéricas y proporciona una medida natural de importancia de variables, propiedades que lo hacen especialmente adecuado para problemas de clasificación con features comportamentales como los del presente trabajo.

D. Gradient Boosting y XGBoost

Los métodos de gradient boosting representan una estrategia de ensamble distinta a la de Random Forest. En lugar de entrenar árboles independientes en paralelo y promediar sus predicciones, el boosting construye una secuencia de árboles en la que cada nuevo árbol se especializa en corregir los errores cometidos por el ensamble parcial anterior. Esta orientación secuencial permite alcanzar un sesgo más bajo que el bagging, que entrena los modelos en paralelo, a costa de una mayor sensibilidad al ruido en los datos y de la necesidad de regularización explícita para evitar el sobreajuste.

XGBoost, propuesto por Chen y Guestrin [13], es una implementación de gradient boosting que incorpora regularización en la función objetivo, manejo nativo de valores faltantes y optimizaciones algorítmicas que lo han convertido en una referencia para problemas de clasificación sobre datos tabulares. Para contextos con clases desbalanceadas, XGBoost provee el parámetro `scale_pos_weight`, que pondera el error sobre la clase positiva durante el entrenamiento y permite compensar la asimetría sin requerir sobre-muestreo previo de los datos.

E. Regresión logística

La regresión logística modela la probabilidad de que una observación pertenezca a la clase positiva como una función sigmoideal de una combinación lineal de las *features* [11]. Su salida puede interpretarse di-

rectamente como probabilidad, y los coeficientes asociados a cada *feature* expresan el impacto de esa variable sobre el logaritmo de la razón de probabilidades, propiedad que la convierte en una opción de referencia cuando se busca un modelo interpretable. Como contrapartida, asume una relación lineal entre las *features* transformadas y el *logit* del target, limitación que motiva el uso complementario de modelos no lineales como los basados en árboles.

F. Métricas de evaluación para clasificación desbalanceada

La métrica de exactitud, aunque intuitiva, resulta engañosa en escenarios con clases desbalanceadas. Un modelo trivial que asigna todos los casos a la clase mayoritaria puede alcanzar una exactitud aparentemente alta sin haber aprendido nada útil. En el problema de churn de comunicación la prevalencia de la clase positiva no se conoce a priori y puede resultar tanto minoritaria como mayoritaria según el dataset y la ventana de evaluación, lo que obliga a recurrir a métricas que reflejen el comportamiento del modelo sobre cada clase por separado y no sobre el agregado. Las métricas fundamentales en este contexto son la precisión, que mide la fracción de positivos predichos que son verdaderamente positivos, y la sensibilidad o recall, que mide la fracción de positivos reales que el modelo logra recuperar.

Para evaluar el rendimiento de forma independiente del umbral de decisión se utiliza la curva ROC, que grafica la tasa de verdaderos positivos contra la tasa de falsos positivos a lo largo de todos los umbrales posibles, junto con su área bajo la curva o AUC-ROC [17]. Un valor de AUC-ROC cercano a uno indica que el modelo asigna sistemáticamente puntajes más altos a los casos positivos que a los negativos, con independencia del umbral elegido para la decisión final. En el presente trabajo se priorizan recall y AUC-ROC como métricas de evaluación, dado que el costo operativo de no detectar un usuario que entra en churn de comunicación supera al de generar una activación de re-engagement innecesaria.

IV. METODOLOGÍA

A. Dataset y caso de estudio

La validación empírica del modelo se realiza sobre el dataset público *E-commerce Multichannel Direct Messaging 2021-2023*, publicado por Michael Kechinov en Kaggle bajo licencia Community Data Li-

cense Agreement. El dataset contiene aproximadamente 708 millones de registros de mensajes enviados por una empresa de e-commerce de tamaño mediano durante un período de dos años, recopilados mediante la plataforma REES46 CDP. Cada registro representa un mensaje individual enviado a un cliente e incluye el canal de envío, el tipo de campaña (*bulk*, *trigger* o transaccional), los *timestamps* de envío y de cada interacción posterior, y variables binarias de resultado que registran apertura, *click*, compra atribuida, rebote, queja por *spam*, bloqueo y desuscripción. El dataset comprende 16,8 millones de identificadores de cliente únicos como destinatarios de mensajes, de los cuales 9,9 millones presentan al menos un mensaje recibido durante la ventana de evaluación y constituyen la población evaluable. Se complementa con tres archivos auxiliares: metadata de campañas, fecha de primera compra por cliente y calendario de eventos comerciales relevantes para el período analizado.

Los canales con mayor representación son *email* y *mobile push*, que concentran la totalidad del volumen significativo de mensajería en el dataset. El canal in-app, que forma parte del concepto teórico de *churn* de comunicación tal como se introduce en la sección I, no se encuentra disponible en datasets públicos con la granularidad de eventos requerida para este trabajo. La metodología se diseña entonces sobre los dos canales de mayor volumen, manteniendo una estructura extensible que permitiría incorporar un tercer canal de mensajería sin alterar el *pipeline* de procesamiento ni la definición operativa del target.

B. Definición del target y partición temporal

La predicción de *churn* de comunicación requiere una definición operativa que distinga el cese de interacción con los canales de mensajería del cese de actividad en la plataforma. Para este trabajo, el target se define a nivel de usuario sobre una ventana temporal de evaluación: un usuario recibe la etiqueta de *churn* de comunicación si durante esa ventana fue alcanzado por al menos un mensaje en cualquiera de los canales disponibles pero no registró ninguna apertura ni *click* en ningún canal. Los usuarios que abrieron o clickearon al menos un mensaje durante la ventana de evaluación reciben la etiqueta complementaria, y los usuarios que no recibieron ningún mensaje en ese período se excluyen del análisis por no resultar informativos respecto del fenómeno estudiado.

La partición de los datos sigue un esquema temporal estricto en lugar de aleatorio, con el objetivo de evitar fugas de información futura hacia el conjunto

de entrenamiento. Los primeros dieciocho meses del dataset constituyen el período de observación, sobre el cual se construyen las *features* comportamentales de cada usuario, y los últimos seis meses constituyen el período de evaluación, sobre el cual se determina el *target*. Esta separación garantiza que el modelo nunca observa información proveniente del período en el que se define la variable a predecir, replicando las condiciones de despliegue en un entorno CRM real en el que las *features* se calculan sobre el pasado y la predicción opera sobre el futuro.

C. Ingeniería de features

A partir del período de observación se construye un vector de *features* por usuario que combina señales comportamentales de cada canal individual con indicadores derivados que capturan la dinámica *cross-channel* y la evolución temporal reciente. Para cada canal se calculan métricas de respuesta agregada (tasa total de apertura y de *click*), métricas de respuesta reciente (tasa de apertura sobre los últimos treinta y sesenta días del período de observación), métricas de recencia (días transcurridos desde el último *open* y desde el último *click*), métricas de volumen (cantidad de mensajes recibidos) y métricas de fricción (cantidades de rebotes duros, rebotes blandos, desuscripciones y quejas por *spam*). Adicionalmente, para cada usuario se computa la cantidad de compras atribuidas a la interacción con mensajería.

El bloque de *features cross-channel* incorpora la cantidad de canales distintos en los que el usuario abrió al menos un mensaje, la diferencia entre las tasas de apertura por canal y el ratio entre la actividad de los últimos treinta días y el promedio histórico, indicador diseñado para detectar caídas recientes en el *engagement* comunicacional. A estas *features* se suman dos descriptores del contexto de campaña, derivados del cruce con la metadata de campañas: la proporción de mensajes de tipo *trigger* respecto del total y la proporción de mensajes con elementos de personalización. Finalmente, se incorpora la antigüedad del cliente, medida como la cantidad de días transcurridos desde la primera compra registrada hasta el cierre del período de observación. El conjunto de *features* construido se persiste en disco para evitar recálculos en iteraciones sucesivas del experimento.

D. Modelos, tratamiento del desbalance y protocolo de evaluación

Se entrenan tres modelos de clasificación: una regresión logística que cumple el rol de *baseline* interpretable, un Random Forest y un XGBoost como modelos principales basados en ensambles de árboles. La selección obedece a la cobertura conceptual desarrollada en el marco teórico y a la comparabilidad con la literatura de predicción de *churn*, que reporta consistentemente rendimientos competitivos para los modelos de ensamble sobre datos tabulares [14, 16]. Las *features* numéricas se estandarizan únicamente para el caso de la regresión logística, mientras que los modelos basados en árboles se entrenan sobre las *features* originales, dado que no requieren escalado previo.

El tratamiento del desbalance se aplica condicionalmente a la proporción observada de la clase positiva. Si la frecuencia de *churn* de comunicación sobre el conjunto de entrenamiento resulta inferior al veinte por ciento, se aplica sobre-muestreo sintético mediante SMOTE [23] de manera exclusiva sobre el conjunto de entrenamiento, preservando la distribución original en el conjunto de prueba para que las métricas reflejen la prevalencia real del fenómeno. Para Random Forest y XGBoost se realiza una búsqueda de hiperparámetros sobre una grilla acotada, optimizando AUC-ROC mediante validación cruzada estratificada de cinco pliegues. La regresión logística se entrena con regularización por defecto sin búsqueda adicional, en su carácter de *baseline*.

La evaluación de cada modelo se realiza sobre el conjunto de prueba, definido por la partición temporal descrita previamente, y reporta cinco métricas: AUC-ROC, precisión, *recall*, F1-score y la matriz de confusión asociada al umbral de decisión por defecto. Adicionalmente, para Random Forest y XGBoost se construyen gráficos de importancia de *features* que permiten interpretar qué señales comportamentales resultan más relevantes en la predicción del *churn* de comunicación. Los tres modelos se comparan en una tabla resumen que sintetiza el rendimiento sobre las métricas señaladas.

E. Stack tecnológico y reproducibilidad

Si bien el objeto de este trabajo no es la dimensión técnica del *pipeline* sino su contribución metodológica al modelado del *churn* de comunicación, conviene mencionar brevemente las herramientas utilizadas a efectos de reproducibilidad. La implementación se realiza en Python 3.11 sobre un entorno virtual ais-

lado. La carga y manipulación de datos utiliza *pandas* sobre archivos persistidos en formato *Parquet* mediante *pyarrow*, elegido sobre *CSV* por su menor tamaño en disco y por preservar los tipos de las columnas sin necesidad de inferencia. Los modelos se entrenan con *scikit-learn* para la regresión logística y *Random Forest*, y con la biblioteca *XGBoost* para el modelo de *gradient boosting* homónimo. El protocolo de validación cruzada y la búsqueda de hiperparámetros utilizan los componentes *StratifiedKFold* y *RandomizedSearchCV* de *scikit-learn*. La generación de figuras se realiza con *matplotlib*. Todo el *pipeline* ejecuta de forma determinista a partir de una semilla aleatoria global fijada en 42, propagada como *random_state* a cada estimador y a cada componente de particionado, garantizando que dos corridas sobre el mismo dataset produzcan resultados idénticos.

El procesamiento del dataset completo, cuyo tamaño descomprimido supera ampliamente la memoria disponible en una estación de trabajo estándar, se realiza mediante lectura por bloques del archivo *gzipado*, agregando incrementalmente las *features* por usuario sin materializar el dataset completo en memoria. Los resultados intermedios se persisten en disco para permitir re-ejecución parcial del *pipeline* durante la fase de exploración experimental.

V. ANÁLISIS Y RESULTADOS

A. Configuración experimental

La aplicación del *pipeline* sobre el dataset completo identificó 9.906.011 usuarios con al menos un mensaje recibido durante la ventana de evaluación. La partición estratificada con proporción ochenta veinte generó 7.924.808 usuarios de entrenamiento y 1.981.203 de prueba, preservando en ambos subconjuntos la prevalencia observada de la clase positiva, que alcanzó el cincuenta y siete por ciento. La condición para activar *SMOTE* (prevalencia inferior al veinte por ciento) no se cumplió, de modo que los tres modelos se entrenaron sobre la distribución original.

La búsqueda de hiperparámetros para *Random Forest* y *XGBoost* se ejecutó mediante validación cruzada estratificada de cinco pliegues, optimizando *AUC-ROC* sobre un subconjunto estratificado de 500.000 usuarios. La configuración ganadora de cada modelo se reajustó sobre el conjunto de entrenamiento completo. La regresión logística se entrenó directamente sobre el conjunto completo con regularización por defecto, en su carácter de *baseline* interpretable.

B. Comparación de modelos

Cada modelo se evaluó sobre el conjunto de prueba con el umbral que maximiza *F1*. La incertidumbre de las métricas se cuantificó mediante *bootstrap* con doscientas iteraciones, resultando en intervalos de semi-amplitud cercana al milésimo en todas las celdas, magnitud que refleja el tamaño del conjunto de prueba y que no altera el orden relativo entre modelos. La Tabla 1 sintetiza las estimaciones puntuales.

Random Forest obtuvo el mejor desempeño en *AUC-ROC*, con una mejora de 0,036 puntos sobre la regresión logística, y se posiciona como modelo ganador bajo el criterio de evaluación definido en la sección IV.D. *XGBoost* obtuvo métricas estadísticamente indistinguibles de *Random Forest*, dentro del rango de variabilidad estimado por *bootstrap*. La brecha sobre el *baseline* lineal confirma el patrón reportado en la literatura de *churn* sobre datos tabulares [14, 16]. El *recall* superior a 0,94 en los tres modelos es consistente con el carácter mayoritario de la clase positiva y con el enfoque del trabajo, en el que el costo de no detectar un usuario en *churn* de comunicación supera al de una activación de *re-engagement* innecesaria. Las curvas *ROC* y *Precision-Recall* de los tres modelos se muestran en la Figura 1a y en la Figura 1b, y las matrices de confusión asociadas al umbral óptimo *F1* aparecen en las Figuras 2a, 2b y 2c.

C. Importancia de variables

Las Figuras 3a y 3b reportan la importancia de cada *feature* para *Random Forest* y *XGBoost* respectivamente. *Random Forest* la mide como reducción media de impureza acumulada a lo largo de los árboles del ensamble, y *XGBoost* como aporte promedio a la ganancia en las particiones del modelo.

Ambos modelos coinciden en que la *feature* dominante es *ratio_actividad_30d_vs_historico*, el cociente entre la actividad de los últimos treinta días y el promedio histórico del usuario. Este indicador cross-channel concentra la mayor proporción del poder predictivo, hallazgo coherente con la intuición de que una caída reciente del *engagement* respecto del comportamiento habitual es la señal más confiable del estado actual del usuario. A continuación aparecen las tasas y volúmenes de apertura por canal, particularmente para *email* y *mobile push*, junto con las métricas de recencia. Las *features* de fricción (rebotes, desuscripciones, quejas) y los descriptores de contexto de campaña ocupan posiciones marginales en ambos rankings.

Modelo	AUC-ROC	PR-AUC	F1	Prec.	Recall	Umbral
Reg. logística	0,771	0,773	0,791	0,675	0,954	0,448
Random Forest	0,807	0,821	0,804	0,701	0,943	0,416
XGBoost	0,806	0,820	0,803	0,698	0,946	0,868

Cuadro 1: Comparación de modelos sobre el conjunto de prueba en el umbral que maximiza F1.

D. Limitaciones empíricas

La prevalencia del cincuenta y siete por ciento observada sobre el dataset analizado vuelve menos urgente el problema del desbalance pero, simultáneamente, eleva el piso de comparación: el aporte real de un modelo predictivo se mide contra la estrategia trivial de etiquetar a todos los usuarios como *churners*, no contra el azar. La diferencia entre el AUC-ROC del mejor modelo y el de un clasificador aleatorio (0,807 frente a 0,500) cuantifica precisamente ese aporte.

Las *features* derivadas del canal *mobile push* presentan proporciones de valores faltantes elevadas, reflejo de que una fracción mayoritaria de los usuarios no recibió mensajería *push* con volumen suficiente. La imputación con la mediana del subconjunto observado introduce un sesgo conocido que conviene tener presente en toda interpretación causal de la importancia de variables asociadas a ese canal. Por su parte, la *feature* de antigüedad del cliente quedó condicionada por un desfase entre el inicio del archivo auxiliar de fechas de primera compra y el corte de la ventana de observación: una fracción mayoritaria de los usuarios no tiene fecha registrada dentro del rango utilizado, y la fracción restante presenta valores numéricos negativos. La variable conserva poder predictivo en términos binarios pero su valor numérico no admite la interpretación causal de antigüedad esperada.

VI. CONCLUSIÓN

Este trabajo propuso formalizar y modelar el *churn* de comunicación como un objeto de estudio diferenciado del *churn* de producto, definido como el cese de interacción del usuario con los canales de mensajería de una marca mientras este permanece activo en la plataforma, y construyó un *pipeline* predictivo apoyado en algoritmos de *ensemble* que combina señales comportamentales *cross-channel* para anticipar ese estado antes de que se consolide.

La investigación resultó exitosa en sus tres objetivos principales. Estableció una definición operativa del fenómeno aplicable a datasets multicanal de mensajería directa, evaluó tres modelos de clasificación sobre un conjunto de prueba de aproximadamen-


te dos millones de usuarios y obtuvo un AUC-ROC de 0,807 con Random Forest, una mejora de 0,036 puntos sobre la regresión logística que opera como *baseline* lineal. El *recall* superior a 0,94 en los tres modelos confirma que el sistema captura la gran mayoría de los usuarios en estado de *churn* de comunicación, comportamiento alineado con el criterio operativo del trabajo, en el que el costo de no detectar un caso positivo supera al de generar una activación de *re-engagement* innecesaria. El análisis de importancia de variables identificó al indicador *cross-channel* de actividad reciente contra el promedio histórico como la señal predictiva dominante en ambos modelos de *ensemble*, hallazgo que valida empíricamente la hipótesis metodológica central del trabajo: que la integración de señales de múltiples canales en una única *feature* agregada captura información que ningún canal individual aporta por sí solo.

La aplicación del *pipeline* sobre datos reales también reveló limitaciones que conviene documentar. La prevalencia del cincuenta y siete por ciento observada sobre el dataset analizado contradice la asunción inicial de clase minoritaria y eleva el piso de comparación contra el cual debe medirse el aporte real del modelo. La *feature* de antigüedad del cliente quedó condicionada por un desfase temporal entre el archivo auxiliar de fechas de primera compra y el corte de la ventana de observación, lo que limita su interpretación causal. Las *features* derivadas del canal *mobile push* presentaron proporciones de valores faltantes elevadas que la imputación con la mediana solo resuelve parcialmente. Finalmente, el canal in-app, parte del concepto teórico de *churn* de comunicación, no se encuentra disponible en datasets públicos con la granularidad de eventos requerida, por lo que el modelo se construyó sobre dos de los tres canales originalmente propuestos.


Como líneas de trabajo futuro se contemplan cuatro direcciones, ancladas en las limitaciones empíricas identificadas. En primer lugar, la validación del modelo en un entorno CRM operativo con acceso al canal in-app, que permitiría cuantificar el aporte incremental del tercer canal sobre el rendimiento predictivo reportado. En segundo lugar, la comparación cuantitativa contra estrategias de segmentación estáti-

ca, no abordada en este trabajo y necesaria para traducir la mejora en AUC-ROC en beneficio operativo medible. En tercer lugar, la incorporación de señales temporales más finas, como el intervalo entre interacciones consecutivas o los patrones horarios de respuesta, que podrían capturar dinámicas que las *features* agregadas por ventana no representan. Por último, la exploración de arquitecturas de *deep learning* para datos secuenciales, que permitirían modelar la trayectoria de *engagement* del usuario en lugar de una fotografía agregada del período de observación.

VII. APÉNDICE




(a) Curvas ROC.




(b) Curvas *Precision-Recall*.


Figura 1: Curvas comparativas de los tres modelos sobre el conjunto de prueba.



(a) Regresión logística.




(b) Random Forest.




(c) XGBoost.

Figura 2: Matrices de confusión de los tres modelos con umbral óptimo F1.



(a) Random Forest.



(b) XGBoost.

Figura 3: Importancia relativa de las veinte *features* principales para cada modelo.

VIII. REFERENCIAS

- [1] M. Pielot, K. Church, and R. de Oliveira, "An in-situ study of mobile phone notifications," in *Proceedings of the 16th International Conference on Human-Computer Interaction with Mobile Devices and Services (MobileHCI '14)*. ACM, 2014, pp. 233–242. [Online]. Available: <https://dl.acm.org/doi/10.1145/2628363.2628364>
- [2] T. Okoshi, J. Ramos, H. Nozaki, J. Nakazawa, A. K. Dey, and H. Tokuda, "Attelia: Reducing user's cognitive load due to interruptive notifications on smart phones," in *IEEE International Conference on Pervasive Computing and Communications (PerCom)*, 2015, pp. 96–104. [Online]. Available: <https://ieeexplore.ieee.org/document/7146515>
- [3] J. Chaparro-Peláez, Á. Hernández-García, and Á. J. Lorente-Páramo, "May I have your attention, please? an investigation on opening effectiveness in e-mail marketing," *Review of Managerial Science*, vol. 16, no. 7, pp. 2261–2284, 2022. [Online]. Available: <https://link.springer.com/article/10.1007/s11846-022-00517-9>
- [4] X. Zhang, V. Kumar, and K. Cosguner, "Dynamically managing a profitable email marketing program," *Journal of Marketing Research*, vol. 54, no. 6, pp. 851–866, 2017. [Online]. Available: <https://journals.sagepub.com/doi/10.1509/jmr.16.0210>
- [5] F. F. Reichheld and W. E. Sasser, "Zero defections: Quality comes to services," *Harvard Business Review*, vol. 68, no. 5, pp. 105–111, 1990. [Online]. Available: <https://hbr.org/1990/09/zero-defections-quality-comes-to-services>
- [6] S. Gupta, D. R. Lehmann, and J. A. Stuart, "Valuing customers," *Journal of Marketing Research*, vol. 41, no. 1, pp. 7–18, 2004. [Online]. Available: <https://journals.sagepub.com/doi/10.1509/jmkr.41.1.7.25084>
- [7] Airship, "How push notifications impact mobile app retention rates," Airship (Urban Airship), Tech. Rep., 2018. [Online]. Available: <https://grow.urbanairship.com/rs/313-QPJ-195/images/airship-how-push-notifications-impact-mobile-app-retention-rates.pdf>
- [8] M. Alves Gomes and T. Meisen, "A review on customer segmentation methods for personalized customer targeting in e-commerce use cases," *Information Systems and e-Business Management*, vol. 21, 2023. [Online]. Available: <https://link.springer.com/article/10.1007/s10257-023-00640-4>
- [9] P. C. Verhoef, R. Venkatesan, L. McAlister, E. C. Malthouse, M. Krafft, and S. Ganesan, "CRM in data-rich multichannel retailing environments: A review and future research directions," *Journal of Interactive Marketing*, vol. 24, no. 2, 2010.
- [10] M. G. Abdelhady and K. A. Mohamed, "Leveraging artificial intelligence for predictive customer churn modeling in telecommunications: a framework for enhanced customer relationship management," *Scientific Reports*, vol. 15, 2025. [Online]. Available: <https://www.nature.com/articles/s41598-025-30108-z>
- [11] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*, 2nd ed. New York: Springer-Verlag, 2009. [Online]. Available: <https://link.springer.com/book/10.1007/978-0-387-84858-7>
- [12] L. Breiman, "Random forests," *Machine Learning*, vol. 45, no. 1, 2001. [Online]. Available: <https://link.springer.com/article/10.1023/A:1010933404324>
- [13] T. Chen and C. Guestrin, "XGBoost: A scalable tree boosting system," in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM, 2016, pp. 785–794. [Online]. Available: <https://dl.acm.org/doi/10.1145/2939672.2939785>
- [14] J. B. G. Brito, G. B. Bucco, R. Heldt, J. L. Becker, C. S. Silveira, F. B. Luce, and M. J. Anzanello, "A framework to improve churn prediction performance in retail banking," *Financial Innovation*, vol. 10, 2024. [Online]. Available: <https://link.springer.com/article/10.1186/s40854-023-00558-3>
- [15] A. Barsotti, G. Gianini, C. Mio, J. Lin, H. Babbar, A. Singh, F. Taher, and E. Damiani, "A decade of churn prediction techniques in the TelCo domain: A survey," *SN Computer Science*, vol. 5, 2024. [Online]. Available: <https://link.springer.com/article/10.1007/s42979-024-02722-7>
- [16] P. Lalwani, M. K. Mishra, J. S. Chadha, and P. Sethi, "Customer churn prediction system: a machine learning approach," *Computing*, vol. 104, no. 2, 2022. [Online]. Available: <https://link.springer.com/article/10.1007/s00607-021-00908-y>
- [17] T. Fawcett, "An introduction to ROC analysis," *Pattern Recognition Letters*, vol. 27, no. 8, 2006. [Online]. Available: <https://www.sciencedirect.com/science/article/abs/pii/S016786550500303X>
- [18] A. G. Martín, A. Fernández-Isabel, I. Martín de Diego, and M. Beltrán, "A survey for user behavior analysis based on machine learning techniques: current models and applications," *Applied Intelligence*, vol. 51, 2021. [Online]. Available: <https://link.springer.com/article/10.1007/s10489-020-02160-x>
- [19] Z. Gharibshah and X. Zhu, "User response prediction in online advertising," *ACM Computing Surveys*, vol. 54, no. 3, 2022. [Online]. Available: <https://dl.acm.org/doi/10.1145/3446662>
- [20] M. Imani, M. Joudaki, A. Beikmohammadi, and H. R. Arabnia, "Customer churn prediction: A systematic review of recent advances, trends, and challenges in machine learning and deep learning," *Machine Learning and Knowledge Extraction*, vol. 7, no. 3, 2025. [Online]. Available: <https://www.mdpi.com/2504-4990/7/3/105>
- [21] L. D. Hollebeek, M. S. Glynn, and R. J. Brodie, "Consumer brand engagement in social media: Conceptualization, scale development and validation," *Journal of Interactive Marketing*, vol. 28, no. 2, 2014. [Online]. Available: <https://www.sciencedirect.com/science/article/abs/pii/S1094996813000649>
- [22] L. D. Hollebeek and K. Macky, "Digital content marketing's role in fostering consumer engagement, trust, and value: Framework, fundamental propositions, and implications," *Journal of Interactive Marketing*, vol. 45, 2019.
- [23] N. V. Chawla, K. W. Bowyer, L. O. Hall, and W. P. Kegelmeyer, "SMOTE: synthetic minority over-sampling technique," *Journal of Artificial Intelligence Research*, vol. 16, pp. 321–357, 2002. [Online]. Available: <https://www.jair.org/index.php/jair/article/view/10302>